Лабораторная работа № 1 — многомерная оптимизация генетическим алгоритмом

Код и все вычисления — `lab1.ipynb`, данные запусков и графики — `results/`, отчёт в PDF — `report.pdf`.

Запуск

```
pip install numpy pandas matplotlib jupyter
cd lab1
jupyter nbconvert --to notebook --execute --inplace lab1.ipynb   # ~10 с
```

- Запускать из папки `lab1`, результаты пишутся в `results/`
- Все параметры — в `GAConfig`; один запуск воспроизводится вызовом `run_ga(GAConfig(), seed)`

1. Постановка и вариант

$N = 10,\ Q = 0,\ Y = 26$

$$V = 1 + ((17N + 7Q + Y) \bmod 20) = 17, \qquad d = 5 + (V \bmod 6) = 10$$

Функция варианта 17 — Sum of Different Powers:

$$\mathbf{x}^* = \arg\min_{\mathbf{x}\in D} f(\mathbf{x}), \qquad f(\mathbf{x}) = \sum_{i=1}^{10} |x_i|^{i+1}, \qquad D = [-1, 1]^{10}$$

- Оптимум: $\mathbf{x}^* = \mathbf{0}$, $f^* = 0$
- Ограничения: только границы $-1 \le x_i \le 1$

2. Представление особи

- Генотип: $\mathbf{x} \in \mathbb{R}^{10}$ (вещественное кодирование)
- Фенотип: $\mathbf{x}$, декодирование не нужно
- Фитнес: $f(\mathbf{x}) \to \min$

3. Алгоритм

Поколенческий ГА с элитизмом:

```
P(0) ~ U(D),  оценка f
   |
   ▼
┌─► evals + (μ-e) > бюджет ? ──да──► вернуть x_best
│       | нет
│       ▼
│   турнирная селекция родителей
│       ▼
│   равномерный кроссовер пар (p_c)
```

```
│      ▼
│   гауссовская мутация (p_m, sigma)
│      ▼
│   отражение от границ, оценка f
│      ▼
│   P(t+1) = e лучших из P(t) U (μ−e) потомков
└──────┘
```

3.1. Операторы

Селекция — турнир (T — $k = 3$ случайных особи):

$$i^* = \arg\min_{j \in T} f_j$$

Кроссовер — равномерный, к паре с вероятностью p_c:

$$(c_i^1,\ c_i^2) = \begin{cases} (p_i^1,\ p_i^2), & u_i < 0.5 \\ (p_i^2,\ p_i^1), & u_i \geq 0.5 \end{cases}, \qquad u_i \sim U[0,1]$$

Дополнительно (раздел 7):

Ранговая селекция ($r_j = 0$ у худшего, $\mu - 1$ у лучшего, $s = 1.7$):

$$p_j = \frac{2-s}{\mu} + \frac{2r_j(s-1)}{\mu(\mu-1)}$$

Кроссовер BLX-α ($\alpha = 0.5$):

$$c_i \sim U\big[m_i - \alpha I_i,\ M_i + \alpha I_i\big], \qquad m_i = \min(p_i^1, p_i^2),\ M_i = \max(p_i^1, p_i^2),\ I_i = M_i - m_i$$

Мутация — гауссовская, каждый ген с вероятностью $p_m = 1/d$:

$$x_i' = x_i + \sigma\,\mathcal{N}(0,1), \qquad \sigma = \sigma_0(u - l)$$

Границы — отражение:

$$x' = 2l - x\ \ (x < l), \qquad x' = 2u - x\ \ (x > u)$$

3.2. Обоснование выбора

- Вещественное кодирование — пространство непрерывное, задано методичкой
- Турнир — не зависит от масштаба f, а значения f в популяции различаются на порядки
- Равномерный кроссовер — перемешивает удачные координаты разных родителей
- Гауссовская мутация — единственный источник новых значений генов; $p_m = 1/d$ — в среднем один ген на особь
- Отражение — потомок остаётся в D и не скапливается на границе
- Элитизм $e = 2$ — лучшее решение не теряется

3.3. Параметры

- $\mu = 50, e = 2, k = 3, p_c = 0.9, p_m = 0.1, \sigma_0 = 0.01$
- Бюджет $10\,000 = 1000 \cdot d$ вычислений f; остановка — исчерпание бюджета
- Инициализация: $U(D)$
- Серия: $R = 30$ запусков, seed $1000 \dots 1029$
- Таблица — `results/base_config.csv`

4. Результаты

метод	best	mean	median	std	worst
ГА	3.7e-12	1.3e-09	3.1e-10	2.2e-09	1.1e-08
случайный поиск	3.9e-03	2.0e-02	1.9e-02	1.1e-02	5.0e-02

- Время одного запуска ГА: ≈ 0.01 с
- Лучший запуск: seed 1006, $f = 3.7 \cdot 10^{-12}$

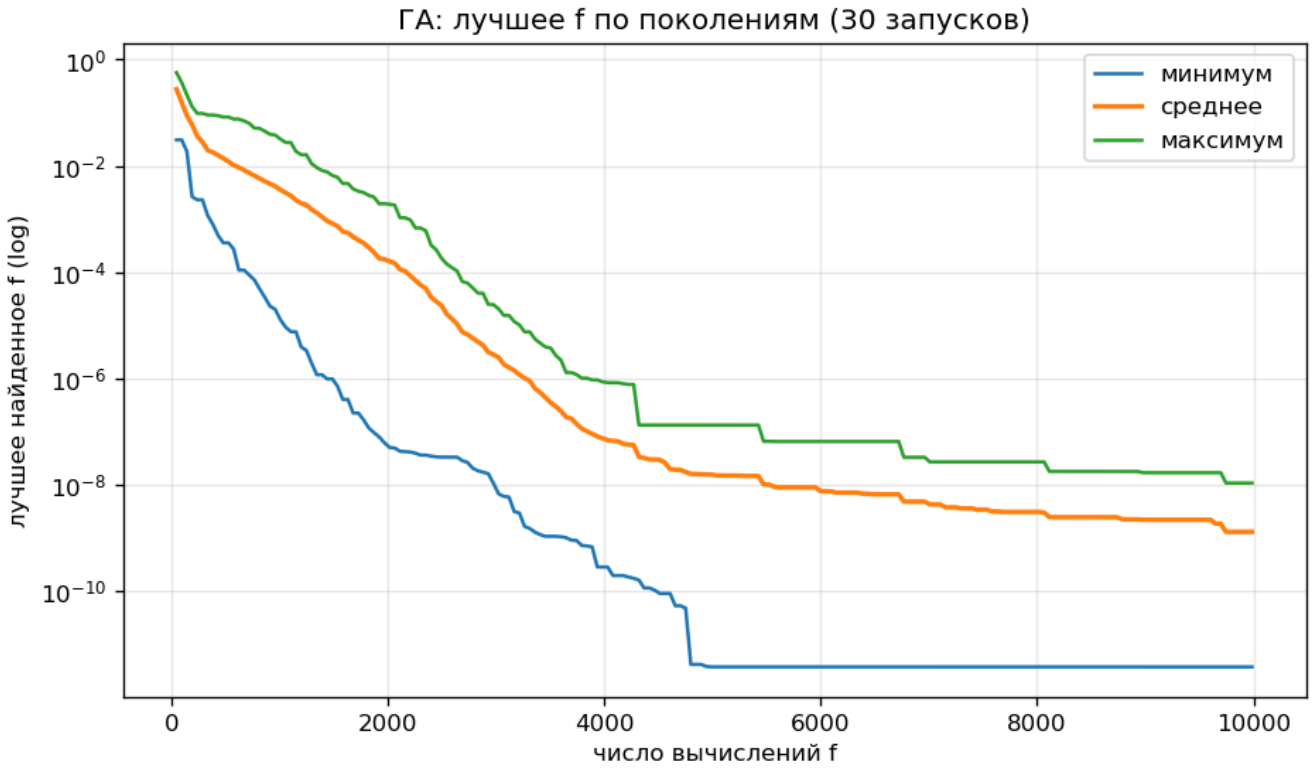


Рис. 1: Сходимость ГА

4.1. Влияние масштаба мутации σ_0

σ_0	best	mean	median	std	worst
0.1	1.8e-09	4.8e-07	5.6e-08	1.2e-06	6.5e-06
0.01	3.7e-12	1.3e-09	3.1e-10	2.2e-09	1.1e-08

σ_0	best	mean	median	std	worst
0.001	3.4e-08	9.5e-04	4.3e-05	2.6e-03	1.3e-02

5. Почему функция трудна для случайного и локального поиска

f выпукла и унимодальна, трудность — **разная чувствительность координат**:

1. Порог точности по координате: $|x_i|^{i+1} < \varepsilon \iff |x_i| < \varepsilon^{1/(i+1)}$; при $\varepsilon = 10^{-8}$: x_1 — 10^{-4}, x_5 — 0.046, x_{10} — 0.19 → один шаг не подходит всем координатам
2. Плато: $\partial f/\partial x_i = (i+1)|x_i|^i \approx 0$ при больших i
3. Случайный поиск: $\mathbb{P}(f < \varepsilon) \le \mathbb{P}(|x_1| < \sqrt{\varepsilon}) = 10^{-4}$ на пробу — и это только по x_1
4. Локальный поиск с фиксированным шагом: большой шаг не уточняет x_1, малый — долго идёт к оптимуму (то же видно в 4.1)

6. Выводы

1. **ГА лучше случайного поиска на ~ 8 порядков** по медиане; худший запуск ГА ($1.1 \cdot 10^{-8}$) лучше лучшего запуска случайного поиска ($3.9 \cdot 10^{-3}$)
2. **Масштаб мутации — компромисс:**
   - $\sigma_0 = 0.1$ — быстрый старт, но шаг $\gg 10^{-4} \to x_1$ не уточняется, медиана $6 \cdot 10^{-8}$
   - $\sigma_0 = 0.001$ — шаг мал → медленно идёт к оптимуму, медиана $4 \cdot 10^{-5}$
   - $\sigma_0 = 0.01$ — лучший из трёх

Почему результат хороший

- $f^* = 0$ известен → ошибка равна f
- Медиана $3 \cdot 10^{-10}$, худший из 30 запусков — $1.1 \cdot 10^{-8}$ → результат устойчив, а не единичный удачный запуск
- Лучшее решение: $|x_1| \sim 10^{-6}$, $|x_{10}| \sim 3 \cdot 10^{-3}$ — все координаты близки к нулю
- **Ограничение:** f выпукла, поэтому градиентный метод тоже бы справился

7. Дополнительное задание

7.1. BLX-α вместо равномерного кроссовера

- Меняется только кроссовер, остальное как в базе
- **Гипотеза:** BLX-α сам создаёт новые значения генов, а мутация с $\sigma = 0.02$ около оптимума (где $|x_i| \sim 10^{-8}$) только портит потомков → без мутации BLX-α будет лучше
- **Проверка:** BLX-α без мутации ($p_m = 0$), остальное то же

кроссовер	best	mean	median	std	worst
равномерный	3.7e-12	1.3e-09	3.1e-10	2.2e-09	1.1e-08
BLX-α	4.9e-21	5.0e-12	1.4e-17	1.9e-11	8.1e-11
BLX-α без мутации ($p_m = 0$)	2.7e-09	8.5e-05	1.3e-06	3.5e-04	1.9e-03

- **BLX-α лучше на ~ 7 порядков** по медиане

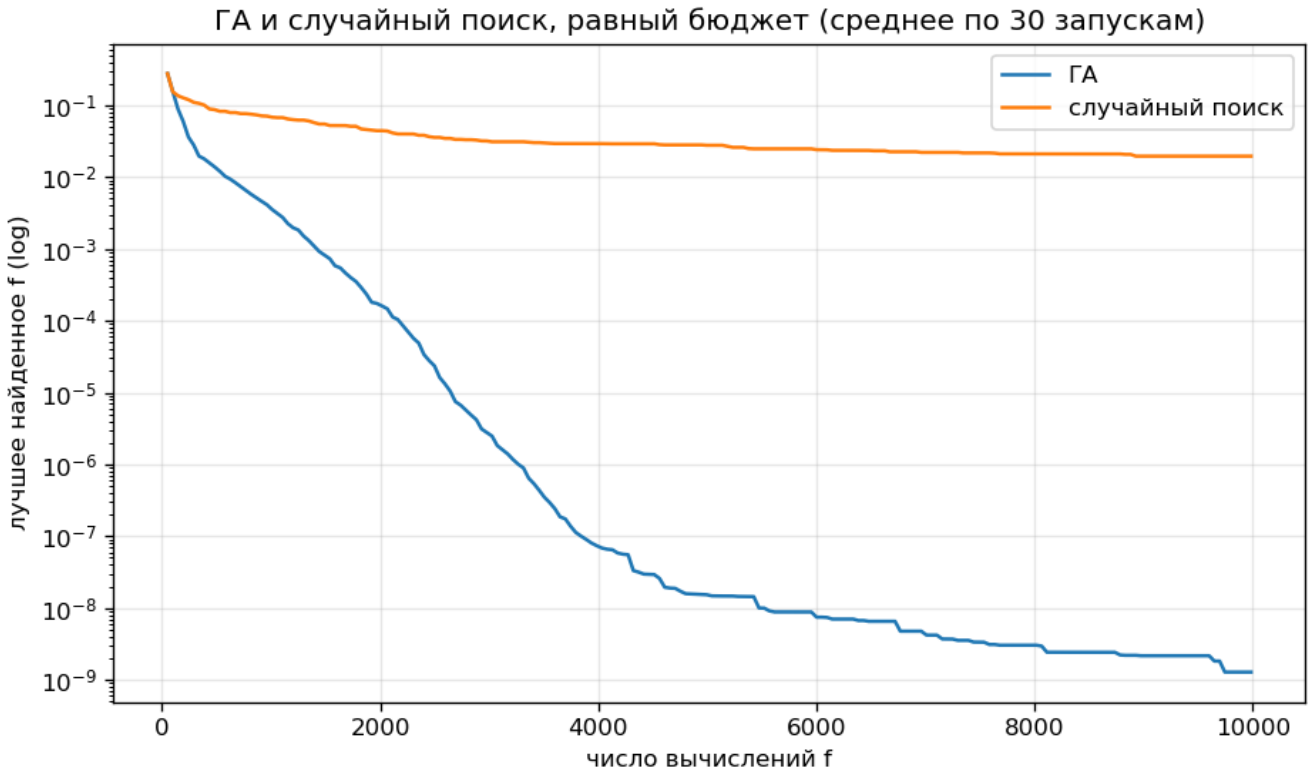


Рис. 2: ГА и случайный поиск

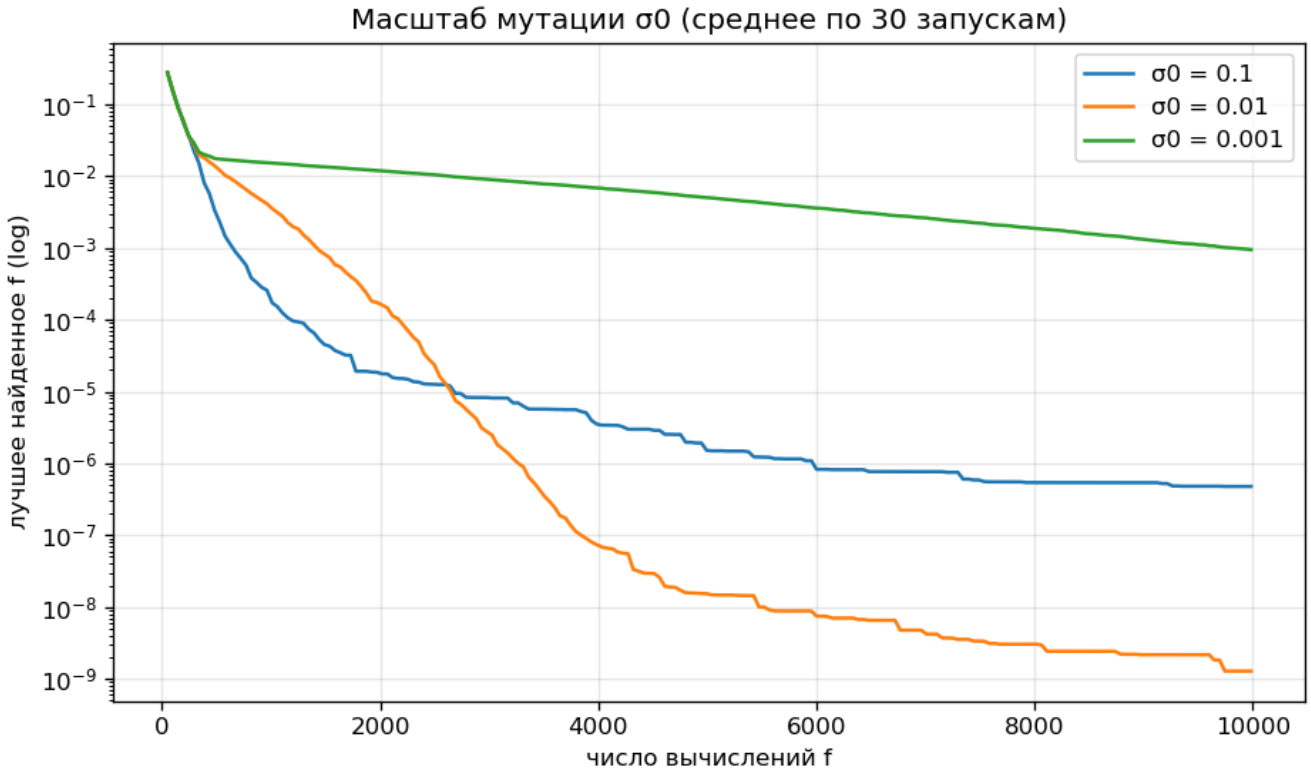


Рис. 3: Масштаб мутации

- Причина: шаг $\propto I_i = |p_i^1 - p_i^2|$ — по мере сжатия популяции шаг уменьшается сам, отдельно по каждой координате
- Среднее $\gg$ медианы: его определяют несколько худших запусков, поэтому линия среднего выходит на плато
- **Гипотеза не подтвердилась: без мутации BLX-α хуже на ~ 11 порядков:** отбор сжимает популяцию $\to I_i \to 0 \to$ шаг BLX-α $\to 0$ раньше, чем популяция дошла до оптимума (преждевременная сходимость). Мутация возвращает разброс, а плохие мутанты отсеиваются отбором и элитизмом

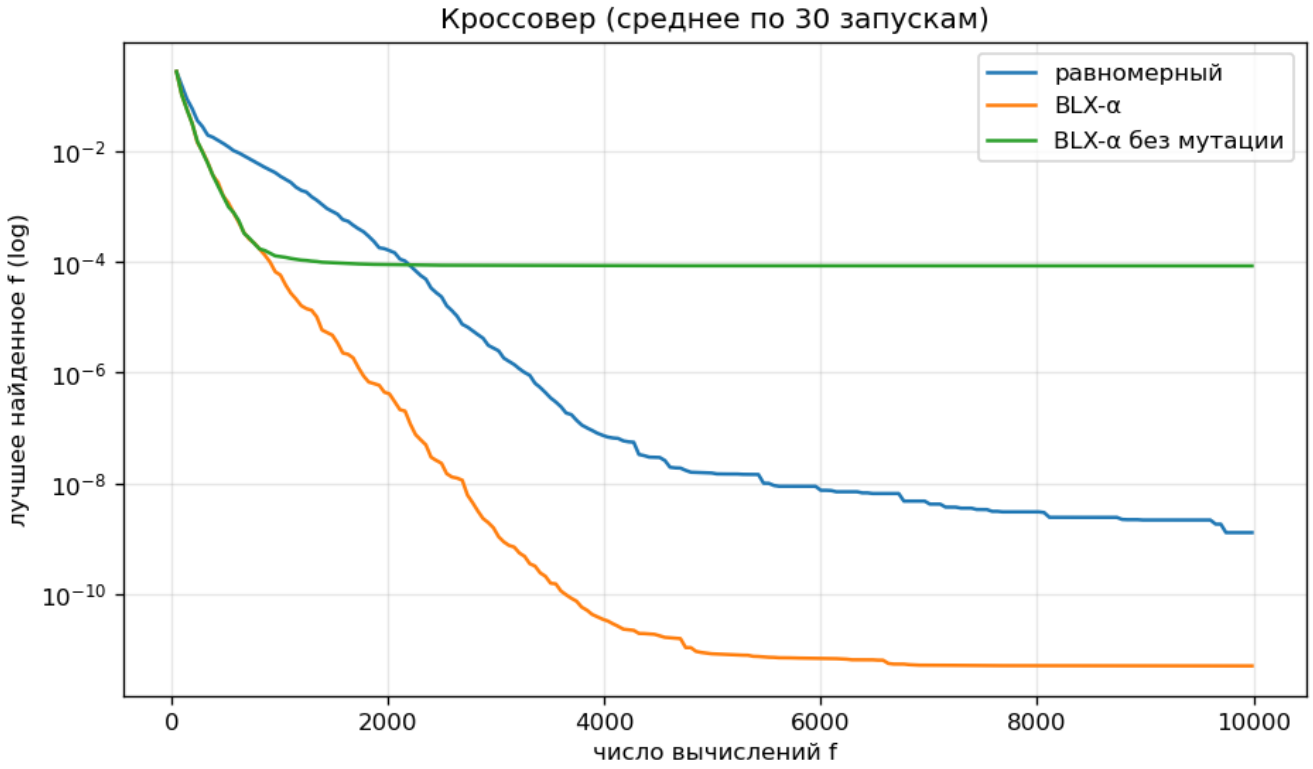


Рис. 4: Кроссовер

7.2. Ранговая селекция вместо турнира

селекция	best	mean	median	std	worst
турнир	3.7e-12	1.3e-09	3.1e-10	2.2e-09	1.1e-08
ранговая	3.0e-11	6.6e-09	2.2e-09	1.4e-08	7.4e-08

- **Ранговая хуже турнира** в ~ 7 раз по медиане
- Причина — слабее давление отбора: вероятность выбрать лучшую особь $s/\mu = 0.034$ у ранговой против $1 - (1 - 1/\mu)^k = 0.059$ у турнира
- Функция без локальных минимумов → выгоднее сильный отбор

7.3. Визуализация сходимости при $d = 2$

- Только для демонстрации: тот же ГА на $f(x_1, x_2) = x_1^2 + |x_2|^3$, $\mu = 30$, $p_m = 1/d = 0.5$, seed 7

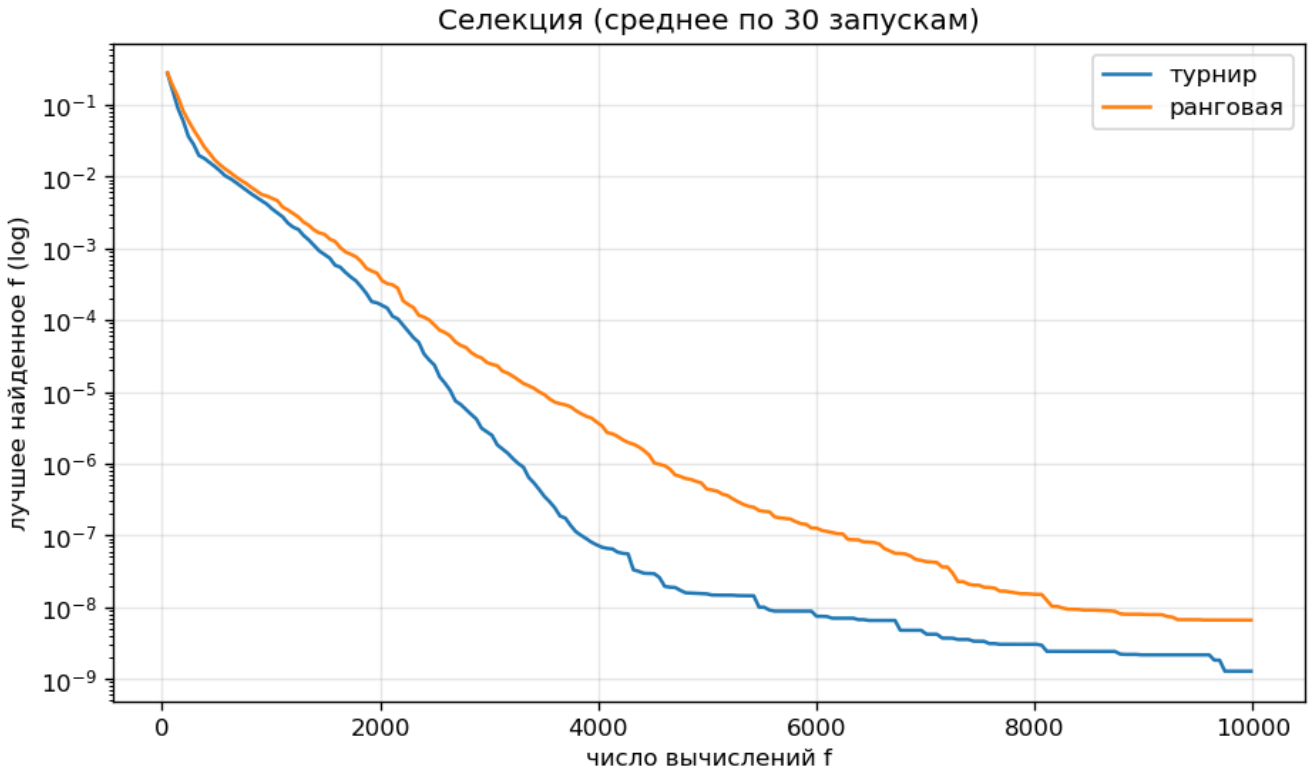


Рис. 5: Селекция

- Поколение 2: точки выстраиваются по горизонтальным и вертикальным линиям — равномерный кроссовер собирает потомков из координат родителей
- К 20-му поколению популяция стянулась к оптимуму

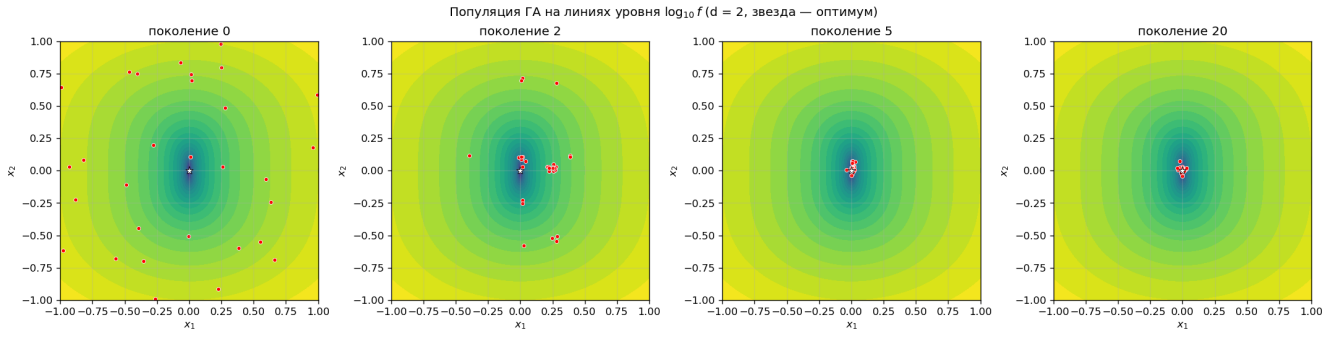


Рис. 6: Популяция по поколениям